



Trabajo Práctico 2 - Informe Escrito

Licenciatura en Ciencias del Comportamiento

Alumnas - Grupo 12

Rocío Echavarri (34173)

Martina Sacks (34028)

Malena Salamida (34114)

Profesores

María Noelia Romero

Tomas Enrique Buscaglia

Asignatura

Ciencia de Datos (CC408) - Tutorial 3 - Lunes 14:00

Fecha de presentación

26 de Septiembre de 2025


Parte I

Distribución de edad y línea de pobreza

El análisis de la distribución de edades en la región noroeste (NOA) revela una mayor concentración de individuos en el rango entre diez y treinta años y una menor representación de edades avanzadas, particularmente a partir de los sesenta años.

Por otro lado, al analizar la distribución de edades según la posición con respecto a la línea de pobreza, se identificó una predominancia de niños y menores de treinta años en el grupo en condición de pobreza (Figura 1). El gráfico de la densidad poblacional del grupo sobre la línea de pobreza muestra una distribución más equilibrada, con una mayor concentración de individuos entre veinte y cuarenta años (Figura 1). Esto podría estar asociado a una mayor estabilidad económica a lo largo del ciclo de vida.

Figura 1. Distribución general de edad (Panel A) y según condición de pobreza (Panel B)



Nivel educativo

En primer lugar, se creó la variable `educ` utilizando los datos de las variables `CH12` (nivel más alto cursado), `CH13` (si finalizó dicho nivel) y `CH14` (último año de escuela/colegio aprobado). Se recodificaron estas variables para que las versiones de 2005 sean consistentes con el método de 2025, que aplica categorías numéricas y enteros ([Anexo I](#)).

Muchos de los datos faltantes de `CH14` (6561) podían identificarse combinando la información disponible en `CH12`, es decir, si alcanzaron al menos educación secundaria, y en `CH13`, si la completaron. De esta manera, se imputaron 4335 datos de `CH14` para los cuales se podía inferir que la persona había completado la secundaria.

Se hallaron 871 casos de valores vacíos para la variable `educ`, de los cuales 245 corresponden al rango etario de entre dieciocho y treinta años. Estos casos se omitieron del

análisis descriptivo de la variable, realizado sobre un total de 18168 observaciones, pero se conservaron en la base de datos.


El promedio de años de educación para el NOA es de 9,79 años, lo que indica que la población media alcanzó gran parte de la educación secundaria. La desviación estándar de 4,24 años señala una dispersión moderada: si bien hay muchas personas que completan la secundaria, existen otras personas que no han logrado completar ni siquiera la primaria.

Por otro lado, se identificó un mínimo de cero años de educación, correspondiente tanto a bebés como a adultos que no han recibido ninguna educación formal. En contraposición, el máximo nivel educativo alcanzado por la muestra es de diecinueve años, correspondientes a un nivel universitario o de posgrado. Adicionalmente, se halló que la mitad de los encuestados en la región completó menos de diez años de educación formal.

Distribución de ingreso y línea de pobreza

Para comparar los ingresos familiares del primer trimestre de 2005 con los del primer trimestre de 2025 se incorporó el efecto de la inflación a los valores del ingreso total familiar (ITF). Para ello, se tomaron los valores del primer trimestre de 2005 de la variable ITF y se multiplicaron por 969,61, que corresponde al monto de conversión de ajuste a valores de 2025 (Calculadora de Inflación, s. f.). Una vez actualizada la variable ITF, se realizó un histograma (Figura 2, Panel A) y una distribución de kernels para pobres y no pobres (Figura 2, Panel B) de la variable `ingreso_total_familiar`. Dado a la actualización de valores, la línea de pobreza presenta el valor de la canasta básica de 2025, valuada en \$365.177.

Figura 2: Histograma de ITF (Panel A) y distribución del ITF por condición de pobreza (Panel B)



Los patrones de distribución observados en la Figura 2 se explican por la sobrerepresentación de ciertos hogares. Dado que el eje horizontal corresponde al ingreso del hogar de cada individuo, los hogares más numerosos adquieren mayor peso en la distribución y, en consecuencia, la recta graficada en color rojo no segmenta individuos por encima y por debajo de la línea de pobreza.

En el Panel A se observa una gran proporción de individuos cuyo ingreso de hogar supera levemente la línea de pobreza, pero permanece en un nivel de ITF bajo. Asimismo, a medida que aumenta el nivel de ingreso del hogar del encuestado, la frecuencia disminuye, es decir, que la mayor parte de la muestra de la región NOA pertenece a hogares con ingresos moderados a bajos. Por otra parte, hay aproximadamente 3.500 hogares detrás de la línea de pobreza, es decir, que una proporción significativa de familias no cuentan con el ingreso suficiente para costear una canasta básica.

En el Panel B, al aplicar la variable dicotómica de la condición de pobreza, se puede distinguir claramente que los hogares pobres se concentran en los ingresos más bajos y cercanos a la línea de pobreza, mientras que los hogares no pobres tienen una dispersión de ingresos más amplia y un nivel de ingresos más alto. Por último, la presencia de personas categorizadas como “pobres” a la derecha de la línea de pobreza se debe al fenómeno de sobrerepresentación detallado anteriormente.

Horas trabajadas del jefe del hogar

Se identificaron 17.209 jefes de hogar, de los cuales 919 (5,34%) no reportaron horas trabajadas en ninguna ocupación, en tanto que otros 172 (1%) declararon valores implausibles superiores a 84 horas semanales. Estos últimos fueron excluidos por un potencial error en la carga de datos. A partir del conjunto depurado se creó la variable `horastrab`, que suma las horas trabajadas en la ocupación principal (`PP3E_TOT`) y en otras ocupaciones (`PP3F_TOT`).

La estadística descriptiva de `horastrab` reveló un promedio de aproximadamente 29 horas semanales y, además, que la mitad de los encuestados trabaja menos de 30 horas semanales. La desviación estándar de aproximadamente 23 horas semanales indica que hay una gran heterogeneidad en el tiempo de trabajo en la población: mientras que algunos trabajan 0 horas, otros alcanzan valores máximos de 84 horas semanales. Estas estadísticas sugieren que existen tanto jefes de hogar que están desempleados/inactivos como otros que tienen jornadas laborales extensas, que puede ser resultado de tener múltiples ocupaciones.

Información descriptiva de la base utilizada

La base de datos final que se utilizará para analizar la región noroeste consta de 19.039 observaciones de 45 variables (Tabla 1). Dado que uno de los ejes de análisis es la posición de los encuestados con respecto a la línea de pobreza, es relevante notar que la variable `pobre` no contiene valores NAs para ninguno de los dos períodos analizados. En el primer trimestre de 2005, el porcentaje de personas bajo la línea de pobreza es del 44,97%, mientras que para 2025 este porcentaje asciende a 50,65%.

Tabla 1: Resumen de la base final para la región NOA

	2005	2025	Total
Cantidad observaciones	9348	9691	19039
Cantidad de observaciones con NAs en la variable “Pobre”	0	0	0
Cantidad de pobres	4204	4909	9113
Cantidad de No Pobres	5144	4782	9926
Cantidad de variables limpias y homogeneizadas	45	45	45

Parte II

Correlaciones en la región noroeste

Se construyó una matriz de correlación ([Anexo II](#)) para las variables `CH06` (edad), `edad2` (edad al cuadrado), `educ` (nivel educativo), `ingreso_total_familiar`, `IX_TOT` (cantidad de personas en el hogar) y `horastrab` (horas semanales trabajadas por el jefe de hogar).


Se identificó una correlación fuerte y positiva ($r = 0,96$) entre la edad y la edad al cuadrado, lo cual es lógico dado que la segunda fue construida a partir de la primera. Asimismo, la edad y la edad al cuadrado presentan correlaciones débiles y negativas con la cantidad de miembros del hogar ($r = -0,32$ y $r = -0,30$ respectivamente). Esto es esperable dado que el tamaño de los hogares está asociado a dinámicas del ciclo de vida, de modo que pueden expandirse durante la adultez y achicarse al llegar a edades avanzadas. A su vez, el número de integrantes del hogar presenta una correlación débil y negativa con el nivel educativo ($r = -0,29$), que podría explicarse dado que a menudo las personas con menor nivel educativo tienen menor acceso a recursos de planificación familiar. Por último, el ingreso total familiar presenta una correlación débil y positiva con el nivel educativo ($r = 0,25$). Si

bien existen múltiples factores determinantes del ingreso familiar, la literatura muestra que aquellas personas con mayor acceso a educación formal tienden a percibir un mayor ingreso (por ejemplo, Llanos y Kepa, 2022). Las correlaciones restantes fueron menores a 0,2 y -0,2 y la mayoría oscilaron entre $r = 0$ y $r = 0,1$ ([Anexo II](#)).

Análisis de Componentes Principales (PCA)


A partir de la información del gráfico de correlación, se ejecutó un Análisis de Componentes Principales (PCA, por sus siglas en inglés). A continuación se estandarizaron las variables seleccionadas a partir del cálculo de la media y la desviación estándar de cada variable. El resultado del PCA fueron dos componentes: el primero explica el 36,54% de la varianza, mientras que el segundo explica 22,33%, dando así una varianza total explicada del 59%. En el gráfico de dispersión de componentes (Figura 3) se puede observar que los datos se concentran en el origen y que se extienden principalmente a lo largo del Componente Principal 1, con una dispersión menor a lo largo del Componente Principal 2. Esto sugiere que la mayor variabilidad es capturada por el primer componente. Además, se realizó un gráfico de dispersión que demuestra un nivel de representatividad de los años de educación (*educ*) en los componentes ([Anexo III](#)).

Figura 3: Gráfico de dispersión de componentes principales 1 y 2.




Luego se graficaron con flechas los *loadings* de los componentes, que representan los ponderadores de cada variable utilizada (Figura 4). Este método de visualización permite observar como el primer componente está asociado positivamente con las variables *CH06* y *edad2*, y negativamente con *IX_TOT*; por otro lado, el segundo componente está asociado positivamente con las variables *horastrab*, *educ* e *ingreso_total_familiar*.

Figura 4: Gráfico de dispersión de componentes principales con loadings.



Por último, se graficó la proporción de la varianza explicada para cada uno de los seis componentes (Figura 5) y se observó que los primeros tres componentes principales (PC1, PC2, PC3) explican la mayor parte de la varianza total de los datos, y esta va disminuyendo en los siguiente componentes (PC4, PC5, PC6). Esto sugiere que los primeros dos o tres componentes son los más informativos y cruciales para la reducción de dimensionalidad.

Figura 5: Proporción de varianza explicada por componentes principales 1-6.




Análisis de clústers

Para analizar las tendencias según edad² e ingreso familiar total se generaron tres gráficos de clúster con distintas cantidades de agrupaciones. Elevar la edad al cuadrado dificulta su interpretación, pero resalta las edades más altas y facilita que el algoritmo


distinga entre jóvenes, adultos y mayores. La Figura 6 compara la distribución de pobres y no pobres con un modelo de dos clústers ($k=2$). Se observa que dentro de cada categoría de pobreza existe más heterogeneidad de la que el clustering logra capturar. Los grupos se forman principalmente por edad, más que por nivel de ingreso, por lo que no reflejan fielmente la división entre pobres y no pobres.

Figura 6: Gráfico de clusters ($k=2$) y distribución de la variable “pobre”



Luego, se realizaron gráficos con distribuciones de cuatro grupos ($k=4$) y diez grupos ($k=10$) en comparación con la distribución de la variable que determina la distribución de pobreza en la muestra (Figura 7). De esta manera, al agregar clústers aumenta la distinción en la distribución socioeconómica (ingresos bajos, medios y altos) y etaria (jóvenes y adultos) que se asemeja a la distribución de pobres y no pobres pero no es igual de precisa.


Figura 7: Gráficos de clúster ($K=4$ y 10) y distribución de la variable “pobre”



Se elaboró un gráfico de Elbow (Figura 8) como medida de disimilitud para evaluar la coherencia de la distribución de las observaciones en los clústers. El criterio aplicado fue identificar el punto en que agregar un clúster adicional deja de mejorar significativamente la inercia. En este caso, el número óptimo resultó ser $k=3$, donde se observa el “codo” en la


curva. Este resultado confirma la tendencia a formar tres grupos principales, pero muestra que los clústers no permiten distinguir de manera directa entre pobres y no pobres, sino que reflejan más bien una segmentación del nivel socioeconómico dentro de la muestra.

Figura 8: Gráfico elbow



Finalmente, se utilizó el método de clúster jerárquico para obtener una representación de las observaciones según los subgrupos formados para cada número posible de clusters. A partir de esta información se generó un dendrograma (Figura 9) que muestra cómo las combinaciones entre el ingreso familiar y la edad al cuadrado sigue una distribución de tres grupos diferentes.

Figura 9: Dendrograma



Bibliografía

Calculadora de Inflación. (s. f.). Calculadora de inflación Argentina [Herramienta en línea].
<https://calculadoradeinflacion.com/argentina.html?md=marzo&ad=2005&mh=marzo&ah=2025&q=1&s=cpi>


Llanos, L. y Kepa, A. (2022). Efecto de la educación en el salario de los jóvenes.

Anexo I

[Link al GitHub](#)

Anexo II

Matriz de correlaciones para la región NOA



Anexo III

Gráfico de dispersión de los componentes 1 y 2 según el nivel de educación

