



Trabajo Práctico 3 - Informe Escrito

Licenciatura en Ciencias del Comportamiento

Alumnas - Grupo 12

Rocio Echavarri (34173)

Martina Sacks (34028)

Malena Salamida (34114)

Profesores

María Noelia Romero

Tomas Enrique Buscaglia

Asignatura

Ciencia de Datos (CC408) - Tutorial 3 - Lunes 14:00

Fecha de presentación

31 de octubre de 2025

A. Enfoque de validación

Se llevó a cabo una revisión de literatura a fin de identificar aquellas variables relevantes para predecir la posición respecto a la línea de pobreza de quienes respondieron a la Encuesta Permanente de Hogares (EPH) en el primer trimestre de 2025.

En primer lugar, un análisis de la EPH de 2012 reveló que las mujeres presentaban menores niveles salariales, que estar casado se asociaba con mayores ingresos, que el salario aumentaba proporcionalmente con el nivel educativo y que el empleo informal reducía considerablemente el nivel de ingreso de los trabajadores (Mario y García, 2013). De manera similar, se han realizado diversas investigaciones que sostienen la existencia de un vínculo entre el trabajo informal y la pobreza, incluso controlando por atributos tales como género, edad, región, entre otras (Beccaria et al., 2006; Navarrete y Cristina, 2024).

Por otra parte, un estudio de los datos de la EPH entre 2016 y 2024 reveló que la proporción de pobreza entre los asalariados informales es notablemente superior a la de sus contrapartes con empleo formal (Molina et al., 2025). Adicionalmente, se identificó que los trabajadores manuales y no calificados se encontraban más vulnerables ante la pobreza, al igual que los jubilados y los trabajadores subocupados, es decir, aquellos que trabajan menos horas de las deseadas o necesarias (Molina et al., 2025).

Se han llevado a cabo numerosas investigaciones sobre la pobreza en grupos etarios específicos, particularmente la infancia y la vejez. Con respecto a este último grupo, un trabajo elaborado a partir de la Encuesta Nacional sobre Calidad de Vida de Adultos Mayores de 2012 identificó un menor nivel de pobreza monetaria y un mayor nivel de pobreza no monetaria en adultos mayores comparados con otros rangos etarios (Paz y Arévalo, 2019). Por otro lado, un análisis de microdatos de la EPH de 1992 a 2019 halló una mayor propensión a la pobreza monetaria en niños y adolescentes, seguidos por los jóvenes de entre 18 y 29 años, en tanto que los adultos mayores se vieron menos expuestos a la pobreza en las últimas tres décadas abarcadas por el trabajo (Poy et al., 2021).

Finalmente, un trabajo realizado a partir de los datos de la EPH entre 2003 y 2015 mostró una buena capacidad predictiva de la pobreza teniendo en cuenta la cantidad de miembros del hogar, el nivel educativo, la cobertura médica, etc. (Chagalj y Lagomarsino, 2019). Otros autores también respaldan la idea de que la capacidad de acceso a distintas formas de cobertura de salud, tales como obra social, prepaga, entre otras, está relacionada

con la posición de los individuos con respecto a la línea de pobreza (por ejemplo, Mario et al., 2018).

A partir de la bibliografía recopilada se decidió incorporar el estado civil (CH07), el sexo (CH04), la edad (CH06), la condición laboral (ESTADO), el grado de formalidad del trabajo (EMPLEO), los años de educación (EDUC), la categoría ocupacional (CAT_OCUP), la categoría de inactividad (CAT_INAC), la cantidad de horas trabajadas en la ocupación principal y secundaria (horastrab), la cantidad de miembros del hogar (IX_TOT) y el tipo de cobertura médica (CH08) como predictoras para construir modelos de predicción de pobreza.

A continuación se crearon *dummies* para representar cada categoría como una dimensión binaria y así poder estimar coeficientes y establecer comparaciones entre las variables. A partir de CH07 se creó `en_pareja`, que vale 1 para las categorías “Unido” y “Casado” y 0 en los demás casos.

La categorías “Planes y seguros públicos”, “Obra social y planes y seguros públicos” y “Mutual/prepaga/servicio de emergencia y planes y seguros públicos”, pertenecientes a CH08, asignan valor 1 a la *dummy* `solo_publica`. Usando la misma variable original se agrupó “Obra social (incluye PAMI)”, “Mutual/prepaga/servicio de emergencia”, “Obra social y mutual/prepaga/servicio de emergencia” y “Obra social y mutual/prepaga/servicio de emergencia y planes y seguros públicos” en `con_obra_social_o_prepaga`.

La categoría “Ocupado” de la variable ESTADO corresponde al valor 1 de `ocupado`. Por otra parte, las categorías “Estudiante”, “Ama de casa”, “Menor de 6 años”, “Discapacitado” y “Otros”, de la variable CAT_INAC, se agruparon en `inactivo_no_jubilado`. Por último, “Trabajador familiar sin remuneración”, perteneciente a CAT_OCUP se convirtió en `trabajo_no_rem`, mientras que “Cuenta propia” y “Patrón” se asignaron a `cuenta_propia`.

Durante la limpieza de datos se detectó que un 62% de las observaciones de la variable `horastrab` presentaban un valor de 0, es decir, que más de la mitad de la muestra no trabajaba ([Anexo](#)). En consecuencia, se optó por aplicar una transformación logarítmica a la variable para mejorar la distribución de los valores positivos sin afectar la interpretación de los ceros asociados al desempleo o inactividad laboral (que se controla con la existencia de la variable `ocupado`)

Finalmente, se imputaron valores para edad (CH06), años de educación (EDUC) y cantidad de miembros del hogar (IX_TOT) usando la media, que fue posible ya que el porcentaje de NA en todas las variables mencionadas era menor al 10%.

Se evaluó la multicolinealidad de las variables predictoras mediante el índice de inflación de la varianza (VIF). La mayoría de las variables presentan $VIF < 5$, lo cual refleja valores aceptables (relativamente bajos) de colinealidad. Valores más altos se observan en *ocupado* (12,72) y *log_horastrab* (9,39), lo cual refleja la relación esperable entre estar ocupado y la cantidad de horas trabajadas, por ello se mantuvieron en el modelo ya que ambas son relevantes para el correcto funcionamiento de las predicciones.

Una vez seleccionadas y transformadas las predictoras de interés, se dividió la base de datos de 2025 en entrenamiento, con el 70% de los datos ($n = 6.055$) y testeo, con el 30% restante ($n = 2.596$) y se calcularon las diferencias de medias entre dichas bases usando una prueba *t* de Student (Tabla 1).

Tabla 1. Diferencia de medias de las variables predictoras entre la base de datos de entrenamiento y la de testeo de 2025.

Variable	Media de entrenamiento	Media de testeo	Diferencia	Desviación estándar	Valor <i>t</i>	<i>p</i> -valor
Edad	35,4226	35,5612	-0,1386	-0,0065	-0.2760	0.7825 (-)
Años de educación	10,0294	10,0140	0,0153	0,0036	0.1562	0.8759 (-)
Cantidad de personas en el hogar	4,1803	4,0986	0,0817	0,0405	1.7340	0.0830 (.)
Horas trabajadas (log)	1,4290	1,4076	0,0213	0,0122	0.5187	0.6040 (-)
Género	0,5217	0,5139	0,0079	0,0157	0.6695	0.5032 (-)
En pareja	0,3308	0,3247	0,0061	0,0129	0.5517	0.5812 (-)
Con ocupación	0,4461	0,4426	0,0035	0,0070	0.2980	0.7657 (-)
Seguro médico público	0,0461	0,0443	0,0018	0,0086	0.3663	0.7141 (-)
Obra social o prepagada	0,6091	0,6090	0,0001	0,0001	0.0061	0.9952 (-)
Trabajo no remunerado	0,0045	0,0054	-0,00091	-0,0133	-0.5580	0.5769 (-)

Trabajo propio	0,1116	0,1133	-0,0016	-0,0051	-0.2166	0.8285 (-)
Personas inactivas (excluyendo jubilados)	0,4492	0,4407	0,0085	0,0172	0.7325	0.4639 (-)
<i>Nota: $p < 0,001$ (***) ; $p < 0,01$ (**); $p < 0,05$ (*); $p < 0,1$ (.); $p > 0,1$ (-)</i>						

Se observa que las únicas variables cuya diferencia entre medias tiene un valor absoluto superior a 0,02 son edad, cantidad de horas trabajadas por la persona y la cantidad de personas en el hogar, aunque sólo esta última es levemente significativa ($p < 0,1$). Este comportamiento es deseable ya que se espera que las particiones de datos sean similares. Asimismo, solo las variables de edad, trabajo familiar sin remuneración y trabajador por cuenta propia o patrón presentan una media de testeo mayor a la de entrenamiento, pero dicha diferencia no es significativa.

B. Modelo de Regresión Logística

Se construyó un modelo de regresión logística para predecir la posición con respecto a la línea de pobreza (es decir, “pobre” o “no pobre”) a partir de las variables predictoras mencionadas en el apartado anterior. En la Tabla 2 se presentan los coeficientes estimados, errores estándar y odd-ratios para cada variable.

Tabla 2. Estadística descriptiva de las variables del modelo de regresión logística.


Variable	Coeficiente	Error estándar	Odds ratio	<i>p</i> -valor
Intercepto	0,1913	0,1852	1,2108	0,3015 (-)
Edad	-0,0078	0,0019	0,9923	0 (***)
Años de educación	-0,0496	0,0079	0,9516	0 (***)
Cantidad de personas en el hogar	0,2355	0,0170	1,2656	0 (***)
Horas trabajadas	0,0300	0,0431	1,0305	0,4863 (-)
Género	0,0795	0,0610	1,0827	0,1927 (-)
En pareja	0,2855	0,0734	1,3395	0,0001 (***)
Con ocupación	-0,3454	0,1814	0,7079	0,0569 (.)
Seguro médico público	-0,1760	0,1495	0,8386	0,2391 (-)
Obra social o prepagada	-1,4277	0,0661	0,2399	0 (***)

Trabajo no remunerado	0,5873	0,4391	1,7991	0,1811 (-)
Trabajo propio	0,2264	0,1015	1,2541	0,0257 (*)
Personas inactivas (excluyendo jubilados)	0,4270	0,1251	1,5327	0,0006 (***)
Nota: $p < 0,001$ (***) ; $p < 0,01$ (**) ; $p < 0,05$ (*) ; $p < 0,1$ (.) ; $p > 0,1$ (-)				

Se observa que edad, años de educación, cantidad de personas en el hogar, estar en pareja, tener obra social o prepaga y ser inactivo no jubilado son las variables más significativas ($p < 0,001$) del modelo logístico de predicción de pobreza, seguidas por tener trabajo propio ($p < 0,05$). Además, los coeficientes de edad, años de educación, tener ocupación, tener seguro médico público y tener obra social o prepaga dan cuenta de una relación negativa entre estas variables y la pobreza y, a su vez, sus *odd-ratios* reflejan una disminución de las chances de ser pobre. En cambio, las demás variables presentan una relación positiva y sus *odd-ratios* indican un aumento en las chances de ser clasificado como “pobre”.

Por otro lado, dada su relevancia como variable predictora del modelo, se seleccionó la cantidad de miembros del hogar para graficar la probabilidad de ser clasificado como “pobre” (Figura 1). Las predicciones que se aproximan al extremo superior corresponden a aquellas personas cuyo ingreso no es suficiente para cubrir la Canasta Básica Total (CBT), con la cual el INDEC determina la pobreza. En contraposición, el extremo inferior del gráfico abarca a los individuos que sí cuentan con el ingreso para cubrir la CBT, es decir, que no se encuentran en condición de pobreza. Se observa que, a medida que incrementa la cantidad de miembros del hogar, aumenta la probabilidad de ser clasificado como “pobre” por el modelo de regresión logística, alcanzando un máximo de 12 integrantes que coincide con una probabilidad de pobreza cercana al 1.

Figura 1. Probabilidad predicha de pobreza según la cantidad de personas en el hogar.



C. Método de Vecinos Cercanos (KNN)

Tabla 3. Clasificación de observaciones para distintos valores de k


	K = 1	K = 5	K = 10
Pobre = 0	3319	3305	3607
Pobre = 1	2736	2750	2448

Para elegir un número de vecinos (k) es preciso considerar la relación entre este valor y el trade-off sesgo varianza. Los k pequeños dan lugar a un modelo más flexible, con sesgo bajo y varianza alta, de modo que se aproxima a la realidad pero es más sensible a nuevos datos. Por otro lado, los k grandes producen un modelo más rígido, con sesgo alto y baja varianza, de manera que las predicciones se alejan más de la realidad pero son menos sensibles a nuevos datos. Esto se puede observar en el modelo de predicción realizado con vecinos cercanos con distancia euclidiana y sin ponderación por distancia para tres valores de k : uno pequeño (1), uno intermedio (5) y uno grande (10). En la Tabla 3 se observa cómo a medida que crece el k la cantidad de personas predichas como vulnerables a la pobreza descende.

Las dimensiones consideradas fueron la edad de los encuestados y los años de educación (debido a ser variables continuas), que se escalaron para evitar que la escala de edad altere la estimación de vecinos cercanos. En la Figura 2 se observa una mayor concentración de individuos clasificados como “pobres” en la región correspondiente a


menos años de educación formal. Si bien inicialmente esta tendencia coincide con la etapa de la infancia, se mantiene a lo largo del eje horizontal. Los diferentes valores de k no alteran significativamente la clasificación, pero se produce una diferenciación con menos varianza entre “pobres” y “no pobres” para $k = 10$.

Figura 2. Clasificación de “pobre” y “no pobre” según edad y años de educación aplicando el método de vecinos cercanos con $k = 1$, $k = 5$ y $k = 10$.



Posteriormente se calculó la exactitud (*accuracy*) promedio para distintos valores de k utilizando validación cruzada para controlar el error de sobreajuste. Este análisis reveló un valor óptimo de $k = 16$, cuya exactitud promedio es de aproximadamente 71% (Figura 3).

Figura 3. Precisión promedio para distintas cantidades (k) de vecinos




D. Desempeño de modelos, elección y predicción afuera de la muestra

Para evaluar el desempeño de la regresión logística y el método de vecinos cercanos en la predicción de pobreza, se construyó una matriz de confusión para comparar las predicciones de cada modelo con los valores reales utilizando un umbral $p > 0,5$ (Figura 4). En esta matriz se pueden reconocer el error de tipo I (falso positivo) y el error de tipo II (falso


negativo). En los modelos realizados, existe un mayor número de predicciones con error de tipo II, donde el modelo predice que la persona no es pobre cuando en realidad sí lo es. Además, en el caso de KNN este número es ligeramente más pequeño ($\text{logit} = 440 > \text{KNN} = 390$). Por otro lado, en el caso del error tipo I, sucede cuando el modelo predice que una persona es pobre cuando en realidad no lo es, y cuenta con un mayor número de casos en la regresión logística ($\text{logit} = 357 > \text{KNN} = 290$)

Figura 4. Matriz de confusión para el modelo de regresión logística (izquierda) y el modelo de vecinos cercanos (derecha)



Posteriormente se graficó la curva ROC (Figura 5) para medir la capacidad predictiva de los modelos a partir de su cercanía con el punto óptimo, en el cual la tasa de verdaderos positivos (*tvp*) es igual a uno y la tasa de falsos positivos (*tfp*) es cero. Según las curvas mostradas en la Figura 5, el modelo con mayor capacidad predictiva es el de vecinos cercanos. Además, se calculó el AUC, que es el área por debajo de la curva ROC, el cual debe ser mayor a 0,5 para determinar que el modelo predictivo distingue entre casos positivos y negativos (a diferencia de una distinción al azar). En los modelos estimados, el AUC en ambos casos cumple con este requisito, siendo mayor para vecinos cercanos ($\text{logit} = 0,76$ y $\text{KNN} = 0,81$).

Figura 5. Curva ROC del modelo de regresión logística (rojo) y del de vecinos cercanos (azul)



Adicionalmente, se reforzó el análisis de desempeño empleando la exactitud (*accuracy*), que tomó un valor de 0,6941 (69,29%) para Logit y de 0,738 (73,8%) para KNN, y la precisión (*precision*), que fue de 0,6616 (66,16%) para Logit y de 0,7206 (72,06%) para KNN. Esto indica que tanto la proporción de predicciones correctas sobre el total (*accuracy*), como la proporción de verdaderos positivos entre los casos predichos como positivos (*precision*) es mayor para el modelo de vecinos cercanos. En conjunto, las métricas indican que el modelo KNN tiene un mejor desempeño en la predicción de pobreza.

En el caso del Ministerio de Capital Humano, tiene mayor peso no darle alimentos a una persona en situación de vulnerabilidad. Por ello, en el caso del modelo de predicción se busca reducir los casos donde se predice que $pobre = 0$ cuando en realidad sí es vulnerable. Es decir, en la recomendación del mejor modelo para identificar grupos vulnerables se debe minimizar el error de tipo II y, en consecuencia, el mejor modelo es el de vecinos cercanos con 390 casos de falso negativo en comparación con logit, que resulta en 440. Adicionalmente, se demostró a partir de la curva ROC que el modelo de vecinos cercanos tiene un desempeño ligeramente mejor en la predicción.

Considerando que el mejor modelo de predicción es el de vecinos cercanos, se predijo que la proporción de personas que no respondieron sus ingresos y efectivamente son vulnerables es 0.384 (un 38,4% de la muestra).

[Link al GitHub](#)

Bibliografía

- Beccaria, L., Groisman, F., y Monsalvo, P. (2006). Segmentación del mercado de trabajo y pobreza en Argentina. XLI Reunión Anual de la Asociación Argentina de Economía Política, Universidad Nacional de Salta, Noviembre, 15-16.
- Chagalj, C., y Lagomarsino, B. C. (2019). Predicción de la pobreza en Argentina usando Random Forest. Universidad de San Andrés.
- Mario, A. A., y Garcia, A. O. (2013). Informalidad laboral, pobreza y regiones. Un análisis desde la coyuntura argentina.
- Mario, S., Piovani, J., y Salvia, A. (2018). Servicios de salud: cobertura, acceso y utilización. La Argentina del siglo XXI. Cómo somos, vivimos y convivimos en una sociedad desigual, 265-290.
- Molina, E. C., Sosa, M., y de la Fuente, J. J. R. (2025). Perfiles de la pobreza. Propuestas para su abordaje en la Argentina reciente.
- Navarrete, J., y Cristina, D. (2024). Explorando la relación de largo plazo entre mercado laboral y pobreza en Argentina. Revista Económica, 12(2), 112-125.
- Paz, J., y Arévalo, C. (2019). Pobreza en las personas mayores. Un estudio multidimensional para Argentina. Revista Latinoamericana de Población, 13(25), 75-102.
- Poy, S., Tuñón, I., y Sánchez, M. E. (2021). Pobreza infantil en la Argentina (1992-2019): tendencia y disparidades regionales. Población y sociedad, 28(1), 188-216.

Anexo

Tabla A. Distribución de la variable `horastrab` (horas trabajadas por la persona) previo a la aplicación del logaritmo.

