



**Trabajo Práctico 4 - Informe Escrito**

*Licenciatura en Ciencias del Comportamiento*

**Alumnas - Grupo 12**

Rocio Echavarri (34173)

Martina Sacks (34028)

Malena Salamida (34114)

**Profesores**

María Noelia Romero

Tomas Enrique Buscaglia

**Asignatura**

Ciencia de Datos (CC408) - Tutorial 3 - Lunes 14:00


**Fecha de presentación**

28 de noviembre de 2025

Se construyó un modelo de regresión logística utilizando los datos de la Encuesta Permanente de Hogares (EPH) para el tercer trimestre de 2025 con el objetivo de predecir si los respondientes se ubican por encima o por debajo de la línea de pobreza.

A continuación se aplicaron dos métodos de regularización, Ridge y LASSO, a fin de evaluar la relevancia de las variables predictoras y evitar el sobreajuste del modelo a los datos de entrenamiento. Se empleó una grilla de penalidades  $\lambda = 10^n$ , con  $n \in \{-5, -4, -3, -2, -1, 0, 1, 2, 3, 4, 5\}$  y se graficaron los cambios en los coeficientes para cada valor de  $\lambda$  (Figura 1).

**Figura 1.** Trayectorias de coeficientes bajo regularización.



Con  $\lambda = 10^{-5}$ , la penalización es prácticamente nula, por lo que los coeficientes se mantienen cercanos a los de una regresión sin regularización. Este punto inicial permite observar el efecto de cada predictor previo a la penalización. A medida que  $\lambda$  aumenta, Ridge reduce progresivamente la magnitud de los coeficientes, mientras que LASSO realiza una selección automática de variables y anula los coeficientes que aportan menos información.


Se encontró que los coeficientes de `IX_TOT` y `educ` se sostienen en ambos modelos incluso en niveles de penalidad elevados ( $\lambda = 10^5$ ), lo que indica mayor poder explicativo en la predicción de pobreza. Por otra parte, a partir de  $\lambda = 10^2$  LASSO elimina siete de las doce variables, lo cual sugiere una potencial redundancia o correlación con otras predictoras.

Adicionalmente, se usó 5-fold cross-validation para seleccionar el valor óptimo de  $\lambda$ , es decir, el nivel de penalidad que reduce el error de predicción en modelos regularizados con Ridge (Figura 2) y LASSO (Figura 3). Se evaluó la grilla de valores  $\lambda$  mencionada anteriormente y se registró el error de clasificación en cada partición.

En ambos casos el valor óptimo fue  $\lambda^{cv} = 10^0 = 1$ , que minimizó el error promedio de validación (0.2836 para LASSO y 0.2842 para Ridge). La similitud entre los errores indica una capacidad predictiva comparable entre los modelos.

Las Figuras 2 y 3 muestran la distribución del error de clasificación para cada valor de  $\lambda$ , donde cada caja representa la variabilidad del error en las cinco particiones. Se observa que el error tiende a aumentar a medida que incrementa la penalidad, lo que indica un fenómeno de subajuste.


**Figura 2.** Distribución del error de predicción para cada  $\lambda$  de Ridge.



En la Figura 2 se identifica un error bajo y estable para penalidades pequeñas que aumenta progresivamente con  $\lambda$ . Esto indica una pérdida de capacidad explicativa producto de la reducción excesiva de los coeficientes.


De manera similar, en la Figura 3 se observa que, para valores bajos de  $\lambda$ , el error de LASSO se mantiene relativamente estable y comienza a aumentar a partir de  $\lambda = 10^2$ , lo que sugiere que una penalización excesiva puede eliminar variables relevantes y producir subajuste. No se eliminaron variables para el valor óptimo  $\lambda = 1$ , lo cual sugiere que todas aportan información al modelo con ese grado de penalización.

**Figura 3.** Distribución del error de predicción para cada  $\lambda$  de LASSO.



Para la visualización de la penalidad de LASSO se muestra cómo se eliminan variables a medida que aumenta  $\lambda$  (Figura 4). Para cada valor, se calculó la proporción de coeficientes que el modelo redujo exactamente a cero, indicando qué tan intensa es la selección de variables. Se observa que, con penalidades muy pequeñas, el modelo conserva todas las variables, mientras que a partir de  $\lambda \approx 10^{-1}$  comienza a eliminar una fracción creciente de ellas, hasta llegar a ignorarlas casi por completo para  $\lambda$  más grandes. Esto refuerza lo mencionado anteriormente porque la transición abrupta entre  $\lambda \approx 10^1$  con 8,3% de las variables eliminadas y  $\lambda \approx 10^2$  con 58% de eliminación sugiere que el grupo de variables seleccionadas tiene importancia similar ya que son descartadas simultáneamente cuando la penalidad alcanza este umbral. Además, para  $\lambda \approx 10^3$  el modelo elimina todas las variables y queda únicamente el intercepto, lo que equivaldría a no considerar la información de los predictores.

**Figura 4.** Proporción de variables eliminadas por LASSO en función de  $\lambda$



Los métodos de regularización implementados sobre el modelo de regresión logística en la muestra de entrenamiento no condujeron a la eliminación de ninguna variable, por lo que se conservaron las doce predictoras originales. No obstante, se produjo una leve reducción de coeficientes, tal como se observa en la Tabla 1.

| <b>Tabla 1.</b> Coeficientes estimados con regresión logística para la muestra de entrenamiento del primer trimestre de 2025. |                          |                                     |                                     |
|-------------------------------------------------------------------------------------------------------------------------------|--------------------------|-------------------------------------|-------------------------------------|
| Variable                                                                                                                      | Estimación sin penalidad | Estimación con penalidad L1 (LASSO) | Estimación con penalidad L2 (Ridge) |
| con_obra_social_o_prepaga                                                                                                     | -0,696799                | -0,695592                           | -0,696092                           |
| IX_TOT                                                                                                                        | 0,478872                 | 0,478053                            | 0,478399                            |
| educ                                                                                                                          | -0,213128                | -0,212250                           | -0,213036                           |
| inactivo_no_jubilado                                                                                                          | 0,212332                 | 0,212996                            | 0,212191                            |
| ocupado                                                                                                                       | -0,170806                | -0,160185                           | -0,169671                           |

|                        |           |           |           |
|------------------------|-----------|-----------|-----------|
| CH06                   | -0,165896 | -0,164165 | -0,165925 |
| en_pareja              | 0,133971  | 0,132413  | 0,133686  |
| cuenta_propia_o_patron | 0,071410  | 0,070357  | 0,071416  |
| log_horastrab          | 0,052117  | 0,042250  | 0,051030  |
| mujer                  | 0,039560  | 0,038109  | 0,039471  |
| trabajo_no_rem         | 0,039102  | 0,037977  | 0,039038  |
| solo_publica           | -0,036734 | -0,035530 | -0,036468 |


Si bien el parámetro de penalidad óptimo fue igual para ambos métodos, hubo diferencias en el grado de reducción de coeficientes con respecto a logit sin penalidad. En promedio, Ridge realizó una reducción del 0,2%, en tanto que LASSO redujo un 1,3%. De este modo, se evidencia que las reducciones más significativas fueron llevadas a cabo por el modelo con LASSO, particularmente sobre las variables *ocupado* y *log\_horastrab*.

Como se mencionó previamente, el objetivo de la penalización L2 es reducir el impacto de las variables sin deshacerse de ninguna, en tanto que la penalización L1 permite eliminar predictoras irrelevantes. Sin embargo, para el  $\lambda$  óptimo no se identificaron variables poco informativas para ser descartadas.

Por otra parte, dado que los coeficientes mantuvieron cierto grado de estabilidad entre los tres modelos, puede realizarse una interpretación general. En primer lugar, se halló que contar con cobertura médica prepaga y un mayor nivel educativo reducen la probabilidad de ser pobre ( $\beta \approx -0,69$  y  $\beta \approx -0,213$ , respectivamente). En contraste, estar inactivo (sin ser jubilado) y convivir con más personas en el hogar incrementa la probabilidad de ser pobre ( $\beta \approx 0,212$  y  $\beta \approx 0,478$ , respectivamente).


Luego de regularizar los modelos de regresión logística con Ridge y LASSO, se construyó un árbol de decisión CART que fue podado utilizando un hiperparámetro de costo de complejidad (*ccp\_alpha*) estimado mediante validación cruzada 10-fold. Para seleccionar el hiperparámetro se evaluó una grilla de valores en base a su error de clasificación (Figura 5) y se obtuvo un *ccp\_alpha* óptimo de 0,000384.

**Figura 5.** Error de clasificación del árbol de decisión CART.



Se observa que el mejor modelo, es decir, aquel que minimiza el error de clasificación promedio, contiene las doce predictoras propuestas inicialmente. El valor del hiperparámetro indica que una poda muy leve mejora la generalización del modelo sin afectar su capacidad predictiva. En consecuencia, el árbol resultante ([Anexo I](#)) presenta una estructura compleja, con múltiples nodos y gran profundidad. Para mejorar la visualización, se presenta el árbol obtenido de manera resumida (Figura 6: Panel A).

**Figura 6: Panel A.** Diagrama de árbol CART




El algoritmo CART seleccionó la posesión de una obra social o prepaga como predictora principal de vulnerabilidad socioeconómica. Aquellos sin acceso a cobertura privada (39,1% de la muestra) presentan una probabilidad del 70% de pobreza mientras que quienes tienen cobertura (60,9% de la muestra) el porcentaje restante.

Por un lado, dentro de la categoría de sin cobertura (el lado izquierdo del árbol), se continúa subdividiendo según la situación laboral y los años de educación. De esta manera, las personas con más vulnerabilidad presentan falta de cobertura médica, desocupación y educación menor a 10,5 años. La educación es un factor que se repite en múltiples niveles con puntos de corte como 12,5 y 13,5 años lo que indica que puede actuar como un factor protector en contextos de vulnerabilidad.

Por otro lado, en la rama de cobertura médica privada, quienes residen con más de 4,5 personas presentan una mayor riesgo de vulnerabilidad. Además, se continúa dividiendo por edad (menor a 25 años) y por años de educación (múltiples umbrales nuevamente) lo cual puede significar que incluso con cobertura de salud, los jóvenes con baja educación en hogares numerosos mantienen una vulnerabilidad significativa. Asimismo, el árbol identifica un segmento de personas con baja probabilidad de pobreza (menos del 10%): personas con cobertura, en hogares pequeños, mayores de 25 años y con educación superior a 13,5 años.

Adicionalmente, se construyó un gráfico que muestra la importancia relativa de cada variable en el modelo CART (Figura 6: Panel B), medido por la reducción acumulada del índice de Gini. En concordancia con lo observado en el diagrama de árbol (Figura 5: Panel A), contar con una obra social o prepaga, la cantidad de personas en el hogar y el nivel educativo contribuyen considerablemente a la segmentación entre pobreza y no pobreza.

**Figura 6: Panel B.** Importancia de cada predictor de CART



En cambio, el trabajo no remunerado y la cobertura médica pública tienen un impacto mínimo en el modelo y, en consecuencia, fueron excluidas por el algoritmo de CART. En contraposición, LASSO no eliminó ninguna de las variables del modelo pero sí identificó a las variables solo salud pública, trabajo no remunerado, género y horas trabajadas con un efecto marginal reducido, lo que sugiere que su contribución predictiva individual es menor.


Por último, a fin de evaluar y seleccionar el método de clasificación más adecuado, se construyeron matrices de confusión con umbral  $p > 0,5$  para la regresión logística sin penalidad, el modelo de vecinos cercanos con  $K = 16$ , la regresión logística regularizada con LASSO, por un lado, y con Ridge, por otro, y el árbol de decisión CART (Figura 7).

La regresión logística no penalizada, así como sus dos versiones regularizadas, tienen un rendimiento prácticamente idéntico, exceptuando el hecho de que la regularización con LASSO reduce un caso falso positivo (error tipo I) y aumenta un verdadero negativo.

Por otra parte, el modelo CART genera más falsos positivos que los tres métodos mencionados anteriormente ( $FP = 383$  y  $FP = 357$ , respectivamente) y, en contraposición, produce menos falsos negativos ( $FN = 382$  y  $FN = 440$ , respectivamente). Además, este modelo minimiza el error de tipo II y presenta la mayor tasa de verdaderos positivos, lo que indica una gran capacidad para predecir correctamente la pobreza.

Por último, el modelo de vecinos cercanos minimiza el error de tipo I ( $FP = 290$ ) y su error de tipo II es levemente mayor que el de CART ( $FN = 390$  y  $FN = 382$ , respectivamente).


**Figura 7.** Matrices de confusión con umbral  $p > 0,5$  para regresión logística sin penalidad, vecinos cercanos con K-CV, regresión logística con penalidad LASSO y Ridge y árbol de decisión CART.



En segundo lugar, se graficó la curva ROC (Figura 8), que compara el desempeño de modelos en base a su distancia con respecto al punto óptimo. En este caso, el modelo de vecinos cercanos tiene mejor rendimiento porque su tasa de verdaderos positivos es más cercana a 1 y su tasa de falsos positivos se aproxima más a 0. Este análisis es respaldado por el  $AUC$ , que tiene un valor de 0,815 para KNN, en tanto que los demás modelos presentan un  $AUC \leq 0,765$ . Este indicador también refleja un rendimiento equivalente para la regresión logística sin penalidad, la regularizada con Ridge y con LASSO.

**Figura 8.** Curvas ROC para regresión logística sin penalidad, vecinos cercanos con K-CV, regresión logística con penalidad LASSO y Ridge y árbol de decisión CART.





En tercer lugar, se compararon los modelos a partir de su *accuracy*, esto es, la proporción de predicciones correctas sobre el total, y su *precision*, es decir, la proporción de verdaderos positivos entre los casos predichos como positivos (Tabla 2).

Todos los modelos presentan una *accuracy* superior al 69% y una *precision* mayor al 66%. En concordancia con las métricas consideradas hasta el momento, la regresión logística no penalizada tuvo un rendimiento idéntico al de la regresión regularizada con Ridge. Por su parte, la regularización con LASSO tuvo un desempeño levemente superior en ambas métricas. El modelo de vecinos cercanos tuvo el mejor rendimiento, con una *accuracy* > 73% y una *precision* > 72%, seguido por el modelo CART.

| <b>Tabla 2.</b> Métricas de desempeño para regresión logística sin penalidad, vecinos cercanos con K-CV, regresión logística con penalidad LASSO y Ridge y árbol de decisión CART. |                 |                  |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------|------------------|
| Modelo                                                                                                                                                                             | <i>Accuracy</i> | <i>Precision</i> |
| Regresión logística sin penalidad                                                                                                                                                  | 0,692989        | 0,661611         |
| Vecinos cercanos con K-16                                                                                                                                                          | 0,738059        | 0,720617         |
| Regresión logística con penalidad LASSO                                                                                                                                            | 0,693374        | 0,662239         |
| Regresión logística con penalidad Ridge                                                                                                                                            | 0,692989        | 0,661611         |
| Árbol de decisión CART                                                                                                                                                             | 0,705316        | 0,663740         |

Para complementar estas métricas se calculó el error de los modelos, que fue de 0,307 para la regresión sin penalidad y la regularizada con Ridge, y de 0,306 para la regularizada con LASSO. A continuación se encuentran el modelo CART, con un error de

aproximadamente 0,294, y el modelo de vecinos cercanos, con un error de 0,261.

En conjunto, los indicadores analizados señalan que el modelo de vecinos cercanos con  $K = 16$  presenta el mejor desempeño predictivo porque maximiza la precisión, la exactitud y el área bajo la curva ROC, a la vez que minimiza el error total. Sin embargo, este modelo no es lineal ni fácilmente interpretable, lo que plantea un trade-off entre capacidad predictiva y claridad comunicativa. En contraste, aunque el modelo CART es menos preciso en términos globales, presenta la mayor tasa de verdaderos positivos, lo que indica una alta sensibilidad en la detección de casos de pobreza. Esta característica adquiere particular relevancia en contextos en los que el costo de omitir a una persona vulnerable es alto. Además, al ser ambos modelos no lineales, estos tienen la ventaja de poder disminuir significativamente la proporción de errores de clasificación ( $1 - \text{accuracy}$ ) y mejorar el desempeño predictivo a comparación de métodos lineales.

En conclusión, si bien KNN es el modelo más robusto en términos generales, debido a su facilidad de interpretación el árbol CART podría ser preferible cuando el objetivo es asignar recursos escasos a un grupo específico, como en el caso del Ministerio de Capital Humano. En este escenario, minimizar el error de tipo II, esto es, evitar que individuos pobres se queden sin asistencia, se torna prioritario, y el árbol de decisión proporciona una ventaja para identificar eficazmente a los grupos vulnerables.

## Anexo I

Gráfico CART - Profundidad óptima (11 niveles)

